26 October 2026

MARKET BASKET ANALYSIS

Groceries_dataset

Irwan Lazuardi Saldeni

Table Of Content

- INTRODUCTION
- PROJECT OVERVIEW
- MAIN PROJECT

INTRODUCTION

Irwan Lazuardi Saldeni
@dibimbing Bootcamp Data Analist
Linkedin : irwanls

EDUCATION

Universitas Gadjah Mada
Electrical Engineering
Graduated at Mei 2025

WORK-EXPERIENCE

Project Overhaul PLTU Sebalang
Instrument & Control Technician
June-August 2025

PROJECT OVERVIEW

IOT BUILDING MANAGEMENT SYSTEM
Web-based monitoring for HVAC & fire protection.
Arduino · ThingSpeak

EMPLOYEE PERFORMANCE DASHBOARD
Dashboard to evaluate and monitor employee performance.
Excel · MS Office

DATA PREPROCESSING
Data cleaning, validation, and outlier detection.
Python · Jupyter Notebook

EXPLORATORY DATA ANALYSIS
Explore distributions, patterns, and relationships in data.
Python · Jupyter Notebook

SQL DATA ANALYSIS
Combine datasets and prepare analytical tables.
PostgreSQL

MARKETING PERFORMANCE ANALYSIS
Analyze marketing channel performance, customer conversion funnels, and revenue opportunities to optimize marketing strategies.
Python · Power BI

MAIN PROJECT

- PROBLEM STATEMENT
- DATA UNDERSTANDING
- DATA PREPARATION
- VISUALIZATION
- RECOMMENDATION

Problem Statement

Sumber: Here

Salah satu contoh menarik strategi promo bundling di Indonesia adalah yang diterapkan oleh Indomaret di Bareng, Jombang, Jawa Timur. Berdasarkan penelitian pada tahun 2024, strategi bundling terbukti berpengaruh positif dan signifikan terhadap keputusan pembelian impulsif konsumen, sementara diskon biasa tidak menunjukkan pengaruh yang signifikan.

Sebagai ilustrasi, pelanggan yang awalnya hanya ingin membeli sampo seharga Rp20.000 akhirnya tertarik membeli paket sampo dan sabun seharga Rp29.000 karena merasa mendapatkan keuntungan. Padahal, dari sisi supermarket, nilai transaksi justru meningkat sebesar Rp9.000. Jika modal sampo Rp15.000 dan sabun Rp7.000, laba kotor supermarket meningkat dari Rp5.000 menjadi Rp7.000 per transaksi, atau naik 40%.

Kisah ini menunjukkan bahwa bundling dapat mendorong konsumen membeli lebih banyak produk sehingga nilai transaksi dan potensi keuntungan supermarket meningkat. Maka pada project ini akan menganalisis perilaku konsumen dalam membeli produk, sehingga dapat menetapkan strategi bisnis tertentu

DATA UNDERSTANDING

Data Set : Groceries dataset

Row : 38,765

Column : 3

Nama Kolom	Deskripsi
Member_number	Identitas unik pelanggan yang digunakan untuk membedakan dan melacak aktivitas transaksi setiap pelanggan.
Date	Tanggal transaksi pembelian yang digunakan untuk menganalisis tren dan pola belanja berdasarkan waktu.
itemDescription	Nama atau jenis produk yang dibeli pelanggan dalam suatu transaksi.

```
df=pd.read_csv("Groceries_dataset.csv")
df.head(5)
```

	Member_number	Date	itemDescription
0	1808	21-07-2015	tropical fruit
1	2552	05-01-2015	whole milk
2	2300	19-09-2015	pip fruit
3	1187	12-12-2015	other vegetables
4	3037	01-02-2015	whole milk

DATA PREPARATION

- DATA TYPES & MISSING VALUE
- DUPLICATED
- CONSISTENCY
- OUTLIER
- FEATURE ENGINEERING

DATA TYPES & MISSING VALUE

```
df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 38765 entries, 0 to 38764
Data columns (total 3 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   Member_number    38765 non-null  int64
 1   Date             38765 non-null  str
 2   itemDescription  38765 non-null  str
dtypes: int64(1), str(2)
memory usage: 1.6 MB
```

Dari pengecekan Missing Value, Tidak ditemukan kolom yang terindikasi Missing. Sedangkan untuk tipe data, kolom Date perlu dilakukan perubahan tipe data dati string menjadi date time

```
df['Date'] = pd.to_datetime(df['Date'], format='%d-%m-%Y')
```

DUPLICATED

Pada dataset ini, ditemukan sebanyak 759 (1.95 %) baris yang terindikasi duplikat. Karena tujuan analisis ini adalah untuk mengetahui jenis produk apa saja yang dibeli bersamaan dalam satu transaksi. maka kolom duplikat ini perlu untuk di hapus

```
df[df.duplicated()]
```

	Member_number	Date	itemDescription
5015	2051	11-09-2015	frankfurter
5022	3055	18-08-2015	other vegetables
5044	1994	11-03-2015	whole milk
5055	1682	25-06-2015	pip fruit
5059	4324	05-01-2015	sausage
...	...	...	...
38614	2027	26-02-2014	domestic eggs
38684	2936	07-03-2014	newspapers
38685	2311	13-03-2014	pot plants
38722	3834	18-05-2014	salty snack
38723	1146	23-05-2014	yogurt

759 rows × 3 columns

CONSISTENCY

Karena banyaknya data kategorik pada dataset ini, maka perlu bantuan AI untuk melakukan pengecekan konsistensi. Hasilnya, data kategorikal untuk dataset ini sudah konsisten, namun ada issue spasi berlebih sebanyak 436 (1.12%) baris. Sehingga perlu dilakukan penghapusan spasi berlebih untuk kolom *itemDeskription*.

```
pd.set_option('display.max_rows', None)
df["itemDescription"].value_counts().sort_index(ascending=True)
```

```
itemDescription
Instant food products          60
UHT-milk                      320
abrasive cleaner               22
artif. sweetener               29
baby cosmetics                  3
bags                            4
baking powder                 121
bathroom cleaner               17
beef                          508
berries                       326
beverages                     248
bottled beer                  678
bottled water                 908
brandy                         38
brown bread                   563
butter                        527
butter milk                   263
```

```
pd.reset_option('display.max_rows')  #mereset kembali option 'display.max_rows'
```

`itemDescription`	167 kategori produk, terdapat 440 baris dengan spasi di akhir nama produk	Perlu cleaning

```
# Mengecek spasi di awal/akhir nama produk
df['itemDescription'].str.strip().ne(
    df['itemDescription']
).sum()
```

```
np.int64(436)
```

```
df['itemDescription']=df['itemDescription'].str.strip() #menghapus spasi berlebih
```

OUTLIER

Setelah dilakukan pengecekan outlier untuk kolom Member number menggunakan boxplot. Dari grafik boxplot, tidak terdeteksi adanya outlier. Sehingga tidak perlu melakukan penangan apapun.

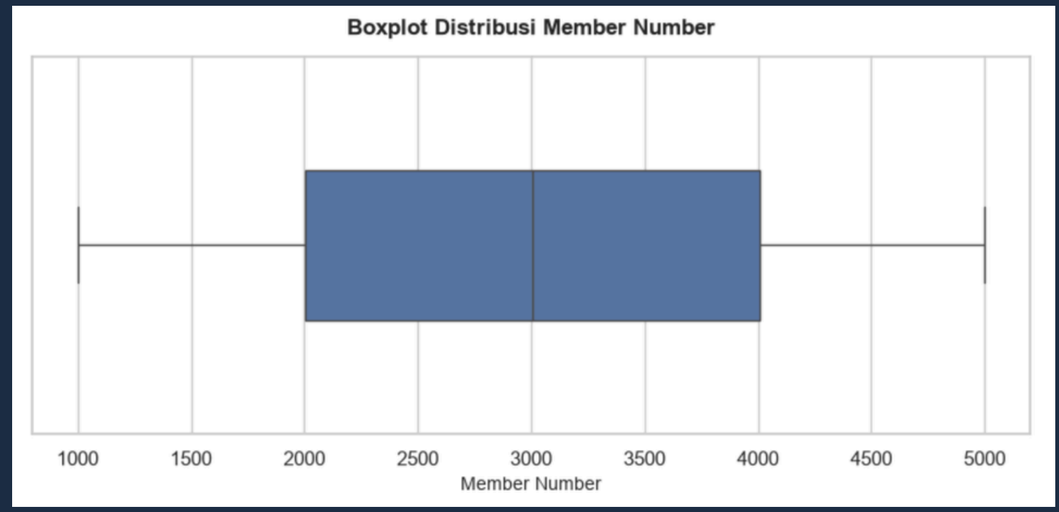

FEATURE ENGINEERING

Karena pada dataset tidak memiliki id transaksi, maka perlu menambahkan Transaction_ID. Tujuannya adalah untuk mengidentifikasi setiap transaksi belanja dan mengelompokkan produk yang dibeli bersamaan dalam satu keranjang. Transaction_ID adalah penggabungan antara kolom Date dan Member number.

```
]: df['Transaction_ID'] = df['Member_number'].astype(str) + '_' + df['Date'].dt.strftime('%d-%m-%Y')
   df.head(5)
```

]:

	Member_number	Date	itemDescription	Transaction_ID
0	1808	2015-07-21	tropical fruit	1808_21-07-2015
1	2552	2015-01-05	whole milk	2552_05-01-2015
2	2300	2015-09-19	pip fruit	2300_19-09-2015
3	1187	2015-12-12	other vegetables	1187_12-12-2015
4	3037	2015-02-01	whole milk	3037_01-02-2015

EXPLORATORY DATA ANALYSIS

Grafik menunjukkan bahwa rata-rata jumlah jenis produk per transaksi meningkat dari 2,2–2,3 produk pada 2014 menjadi 2,8–2,9 produk pada 2015. Meskipun terlihat lonjakan pada awal 2015, peningkatan secara absolut relatif kecil, yaitu sekitar 0,6 jenis produk per transaksi.

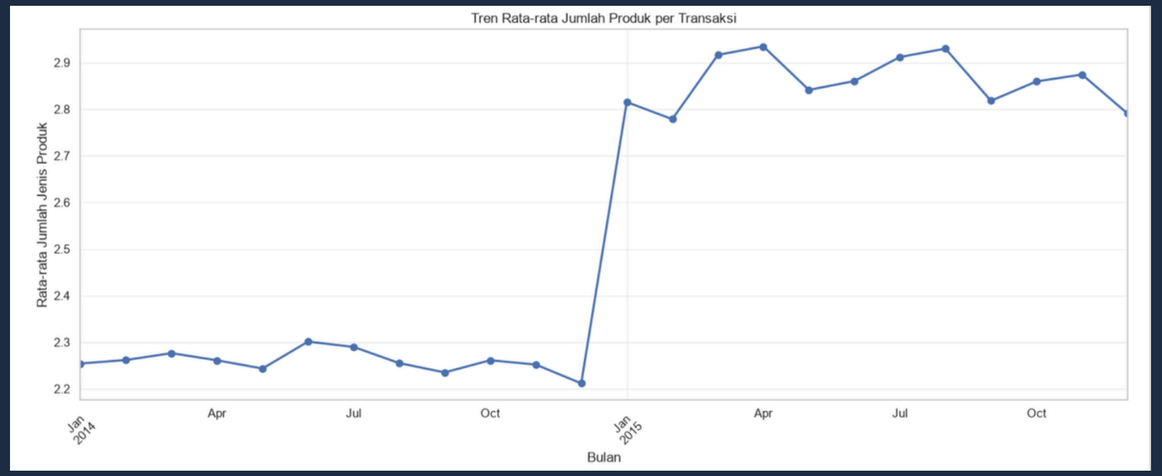

APRIORI ALGORITHM

Pada analisis ini, akan menggunakan algoritma apriori untuk mencari produk-produk yang sering dibeli. Minimal support berapa di 0.2%, dan hasilnya terdapat 330 kombinasi produk untuk selanjutnya dilakukan associate rule.

```
frequent_itemsets = apriori(
    basket,
    min_support=0.002,
    use_colnames=True
)
frequent_itemsets.sort_values(
    by='support',
    ascending=False
)
```

	support	itemsets
123	0.157923	frozenset({whole milk})
78	0.122101	frozenset({other vegetables})
93	0.110005	frozenset({rolls/buns})
104	0.097106	frozenset({soda})
124	0.085879	frozenset({yogurt})
...	...	...
213	0.002005	frozenset({root vegetables, domestic eggs})
229	0.002005	frozenset({frozen vegetables, soda})
196	0.002005	frozenset({coffee, root vegetables})
252	0.002005	frozenset({newspapers, pastry})
61	0.002005	frozenset({kitchen towels})

330 rows × 2 columns

ASSOCIATE RULE

Setelah kombinasi tadi difilter oleh apriori algorithm, selanjutnya membuat associate rule untuk melihat kombinasi produk dengan confidence minimal 5%. Kemudian dilihat kombinasi mana yang memiliki lift yang tinggi.

```
rules = association_rules(
    frequent_itemsets,
    metric='confidence',
    min_threshold=0.05
)
rules[
    ['antecedents', 'consequents',
     'support', 'confidence', 'lift']
].sort_values(
    by='lift',
    ascending=False
).head(10)
```

	antecedents	consequents	support	confidence	lift
75	frozenset({curd})	frozenset({sausage})	0.002941	0.087302	1.446615
30	frozenset({brown bread})	frozenset({canned beer})	0.002406	0.063943	1.362937
31	frozenset({canned beer})	frozenset({brown bread})	0.002406	0.051282	1.362937
99	frozenset({frozen vegetables})	frozenset({sausage})	0.002072	0.073986	1.225966
12	frozenset({sausage})	frozenset({bottled beer})	0.003342	0.055371	1.222000
11	frozenset({bottled beer})	frozenset({sausage})	0.003342	0.073746	1.222000
89	frozenset({frankfurter})	frozenset({other vegetables})	0.005146	0.136283	1.116150
195	frozenset({yogurt})	frozenset({sausage})	0.005748	0.066926	1.108986
194	frozenset({sausage})	frozenset({yogurt})	0.005748	0.095238	1.108986
98	frozenset({frozen vegetables})	frozenset({root vegetables})	0.002139	0.076372	1.097751

VISUALIZATION

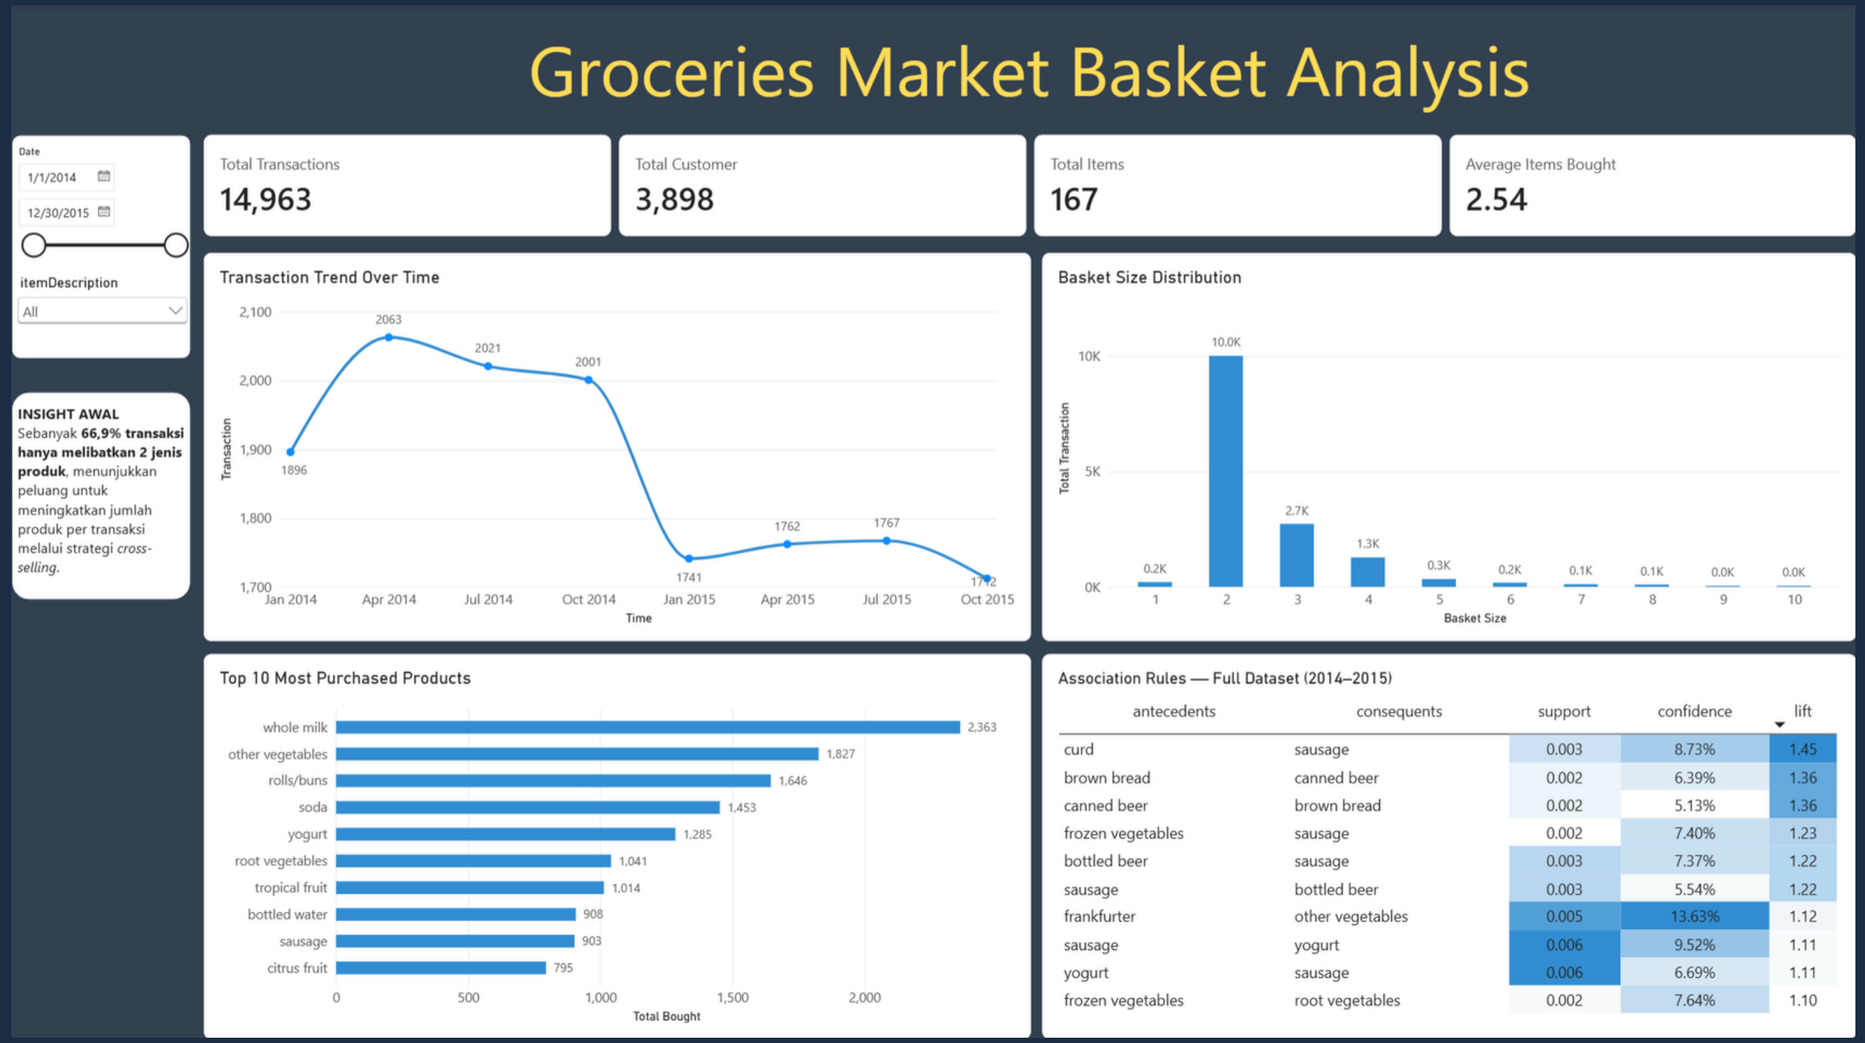

Trend Penjualan Mengalami Penurunan

Tren transaksi menunjukkan kecenderungan **penurunan**, terutama pada tahun 2015, yang menjadi sinyal peringatan bagi perusahaan terhadap potensi melemahnya aktivitas pembelian pelanggan. Kondisi ini perlu menjadi perhatian agar penurunan tidak terus berlanjut.

Salah satu caranya adalah dengan melihat **pola belanja customer**.

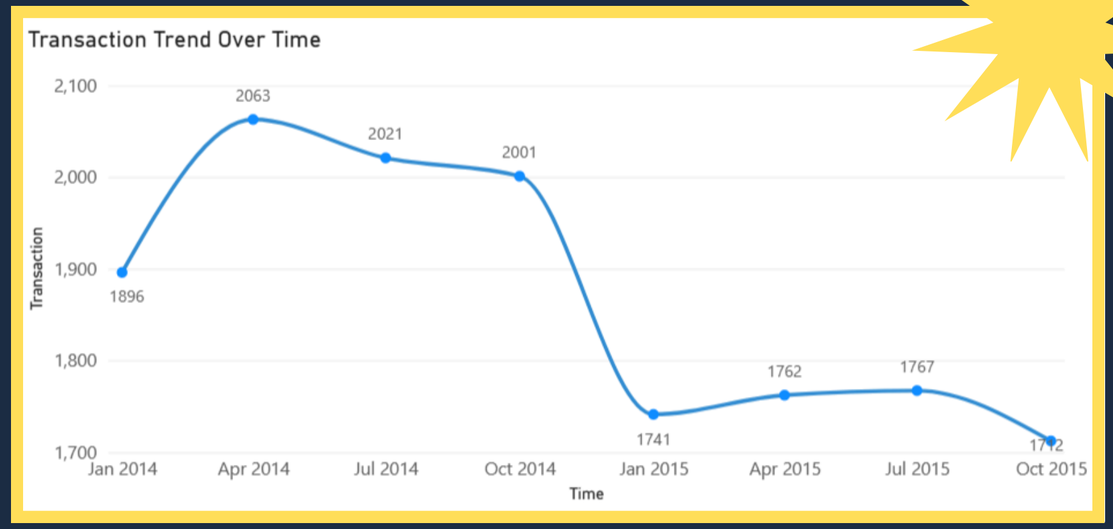

Seberapa banyak jenis barang yang dibeli dalam satu transaksi

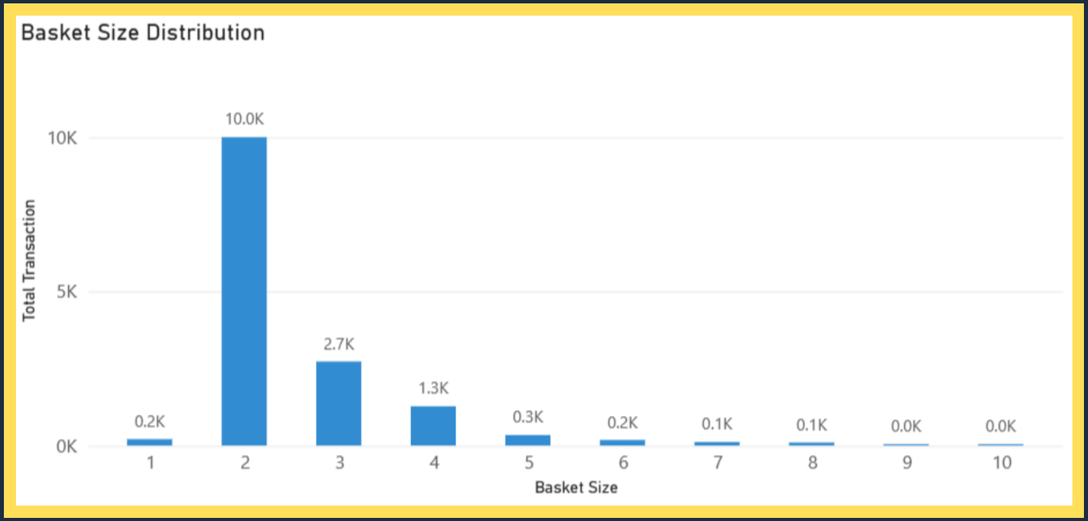

Grafik Basket Size Distribution menunjukkan bahwa mayoritas transaksi pelanggan hanya **terdiri dari 2 jenis produk**, yaitu sebanyak 10.012 transaksi atau 66,91% dari total transaksi. Sementara itu, jumlah transaksi cenderung semakin sedikit seiring bertambahnya jenis produk yang dibeli.

Temuan ini menunjukkan adanya peluang bagi perusahaan untuk mendorong pembelian produk tambahan melalui strategi **cross-selling** atau **rekomendasi produk** yang relevan berdasarkan pola belanja pelanggan.

Untuk dapat menerapkan strategi yang efektif, perusahaan perlu melihat produk apa yang paling laku terjual.

Product yang Sering dibeli

Grafik Top 10 Most Frequently Purchased Products menunjukkan bahwa **whole milk** merupakan produk yang paling **sering dibeli**, dengan kemunculan dalam 2.363 transaksi (15,8%), diikuti oleh other vegetables sebanyak 1.827 transaksi dan rolls/buns sebanyak 1.646 transaksi. Hal ini menunjukkan bahwa produk kebutuhan **sehari-hari**, seperti susu, sayuran, dan roti, **mendominasi pembelian pelanggan**.

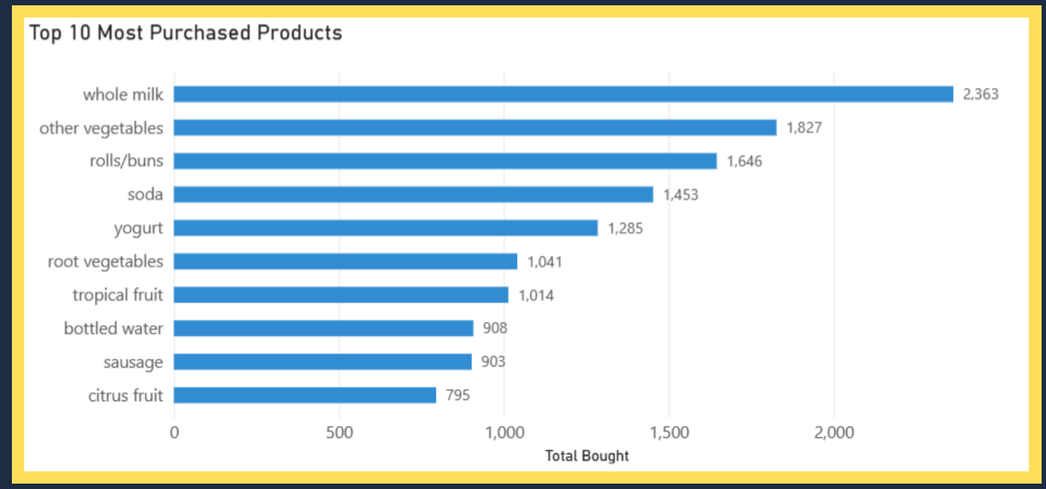

Temuan ini dapat menjadi pertimbangan perusahaan untuk **memprioritaskan** ketersediaan stok produk yang paling sering dibeli guna memenuhi kebutuhan pelanggan dan mengurangi risiko kehilangan penjualan akibat kehabisan stok.

Selain melihat produk yang paling laku, perussahaan perlu melihat pola-pola unik pelangaan dalam membeli produk tertentu

Kombinasi Beberapa Produk

Grafik Association Rules menunjukkan bahwa **sausage** memiliki **asosiasi positif** dengan beberapa produk lain, seperti curd, frozen vegetables, bottled beer, dan yogurt. Hubungan curd - sausage memiliki nilai confidence 8,73% dan lift 1,45, yang menunjukkan **asosiasi paling kuat** di antara kombinasi tersebut. Selain itu, sausage juga memiliki hubungan positif dengan frozen vegetables (lift 1,23), bottled beer (lift 1,22), dan yogurt (lift 1,11).

Temuan ini menunjukkan bahwa sausage berpotensi menjadi produk yang dapat **ditawarkan bersama beberapa kategori produk berbeda**. perusahaan dapat menguji penempatan sausage berdekatan dengan curd dan frozen vegetables, menawarkan rekomendasi sausage kepada pelanggan yang membeli produk tersebut, serta menguji paket bundling.

Association Rules — Full Dataset (2014–2015)

antecedents	consequents	support	confidence	lift
curd	sausage	0.003	8.73%	1.45
brown bread	canned beer	0.002	6.39%	1.36
canned beer	brown bread	0.002	5.13%	1.36
frozen vegetables	sausage	0.002	7.40%	1.23
bottled beer	sausage	0.003	7.37%	1.22
sausage	bottled beer	0.003	5.54%	1.22
frankfurter	other vegetables	0.005	13.63%	1.12
sausage	yogurt	0.006	9.52%	1.11
yogurt	sausage	0.006	6.69%	1.11
frozen vegetables	root vegetables	0.002	7.64%	1.10

Conclusion

- Jumlah transaksi pelanggan mengalami penurunan sekitar 12,5% dari tahun 2014 ke 2015, yang menjadi sinyal perlunya evaluasi aktivitas penjualan perusahaan.
- Whole milk, other vegetables, dan rolls/buns merupakan produk yang paling sering dibeli, menunjukkan tingginya frekuensi pembelian produk kebutuhan sehari-hari.
- Hasil Association Rules menunjukkan bahwa sausage memiliki asosiasi positif dengan curd, frozen vegetables, bottled beer, dan yogurt, sehingga berpotensi menjadi produk untuk strategi cross-selling.

Recommendation

- Menguji Program Bundling Produk Seperti paket Curd + Sausage
- Melakukan penawaran sausage kepada pelanggan yang membeli curd, frozen vegetables, atau yogurt. Penawaran dapat dilakukan melalui kasir, aplikasi belanja, atau penempatan produk berdekatan.

Irwan Lazuardi Saldeni

Thank You

for your time and attention

Github Repository: Here